UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO
Facultad de Ciencias
Licenciatura en Ciencias de la Computación

Asignatura: Inteligencia Artificial

Laboratorio 2.5: Visualización de Datos Avanzada
Temas: Matplotlib, Gráficos Estadísticos y Diagrama de Pareto

Profesora: Dra. Jessica Sarahi Méndez Rincón
Ayudante: Diego Eduardo Peña Villegas
Estudiante: Sita Zoé Sotomayor Carrillo
Fecha: 4 de marzo de 2026

1. Introducción

La visualización de datos es una etapa crítica en cualquier proyecto de Inteligencia Artificial, pues permite identificar patrones, valores atípicos y distribuciones antes de entrenar modelos. En este Laboratorio 2.5, se profundiza en el uso de la librería **Matplotlib** para generar gráficos de líneas, barras e histogramas. Además, se aborda el análisis de datos categóricos y numéricos utilizando DataFrames de Pandas, culminando con la construcción de gráficos complejos como el Diagrama de Pareto para la toma de decisiones.

2. Desarrollo

La práctica se organizó en ejercicios progresivos de visualización:

2.1. Gráficos Básicos con Matplotlib

Se implementaron scripts para generar:

- **Gráficos de Líneas (Plot):** Para visualizar tendencias continuas (e.g., series de tiempo o funciones matemáticas).
- **Gráficos de Barras (Bar):** Ideales para comparar cantidades entre categorías discretas. Se personalizó el color y las etiquetas de los ejes.
- **Histogramas:** Se utilizó `np.random.randn` para generar datos con distribución normal y visualizar su frecuencia acumulada y simple.

2.2. Análisis de Datos Poblacionales

Se trabajó con un conjunto de datos de ciudades y su densidad poblacional. Las operaciones clave incluyeron:

1. **Manejo de Datos Faltantes:** Al agregar nuevas ciudades al DataFrame sin especificar todos sus datos, Pandas asignó automáticamente el valor `NaN` (Not a Number).
2. **Visualización Combinada:** Se generó un gráfico que combina barras (para la densidad individual) y una línea de suma acumulativa (`cumsum`), técnica base para el análisis de Pareto.

```python
import matplotlib.pyplot as plt
import numpy as np

n = 5 + np.random.randn(1000)
plt.hist(n, bins=20)
plt.title("Histograma de Distribucion Normal")
plt.show()
```

Listing 1: Ejemplo de generación de histograma

3. Análisis de Resultados y Reflexión

A continuación, se responden las preguntas de reflexión planteadas sobre el comportamiento de los datos y las gráficas generadas.

1.Los NaN (Valores Nulos)

¿Por qué es útil que Pandas rellene con NaN en lugar de 0?
El uso de `NaN` es crucial porque distingue la *ausencia de información* de un valor numérico real. Si Pandas rellenara con un 0, alteraría estadísticas fundamentales como el promedio (la media bajaría artificialmente) o la desviación estándar. El `NaN` permite que las funciones de agregación (como `.mean()`) ignoren esos registros, manteniendo la integridad estadística del análisis.

2. ¿Cuándo engaña el gráfico de pastel?

Si tuviéramos 50 ciudades, un gráfico de pastel sería ilegible y engañoso porque el ojo humano tiene dificultades para comparar ángulos o áreas similares cuando hay muchas rebanadas pequeñas. En ese caso, un **gráfico de barras** horizontal o un **Tree Map** sería superior, ya que facilita la comparación lineal de las magnitudes.

3. El "Salto" de la CDMX

Al observar la línea acumulativa, el salto pronunciado en la Ciudad de México se debe a que su densidad de población es desproporcionadamente mayor que la de las ciudades previas. En una suma acumulativa, agregar un valor muy grande (un *outlier* o dato dominante) provoca un cambio abrupto en la pendiente de la curva.

4. Utilidad de la Suma Acumulativa (Pareto)

La línea roja (acumulativa) es útil para decisiones de priorización. Por ejemplo, permitiría a un gobierno identificar qué pequeño grupo de ciudades concentra el 50 % o el 80 % de la población total. Esto responde a preguntas como: *"¿En qué 3 ciudades debo invertir para impactar a la mitad de la población del país?"*, optimizando recursos limitados.

5. Investigación: El Diagrama de Pareto

El **Diagrama de Pareto** combina un gráfico de barras descendente con una línea acumulativa. Se basa en el principio del 80/20 (el 80 % de las consecuencias proviene del 20 % de las causas). En este análisis de ciudades, se usaría para demostrar visualmente que interviniendo en unas pocas ciudades densamente pobladas (la çlase A.º el "20

4. Conclusión

Este laboratorio demostró que la elección del gráfico adecuado (barras vs. pastel) es tan importante como el cálculo de los datos. Herramientas como la suma acumulativa y el manejo correcto de valores nulos (`NaN`) son indispensables para evitar sesgos en el análisis. La visualización no es solo estética, es una herramienta analítica para detectar concentraciones de datos, como se vio con el caso de la CDMX.

5. Bibliografía

- Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*.
- McKinney, W. (2017). *Python for Data Analysis*. O'Reilly Media.
- Wilkinson, L. (2005). *The Grammar of Graphics*. Springer.