UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO
Facultad de Ciencias
Licenciatura en Ciencias de la Computación

Asignatura: Inteligencia Artificial

Laboratorio 2.4: Introducción a Librerías de Ciencia de Datos
Temas: NumPy, Pandas y Visualización de Datos

Profesora: Dra. Jessica Sarahi Méndez Rincón
Ayudante: Diego Eduardo Peña Villegas
Estudiante: Zoé Sotomayor
Fecha: 4 de marzo de 2026

1. Introducción

En el ámbito de la Inteligencia Artificial y la Ciencia de Datos, el manejo eficiente de grandes volúmenes de información es crucial. Este laboratorio se enfoca en el uso de las librerías fundamentales del ecosistema de Python: **NumPy** para el cálculo numérico matricial, **Pandas** para la manipulación de estructuras de datos tabulares y librerías de visualización (**Matplotlib/Seaborn**) para el análisis exploratorio. El objetivo es procesar y analizar el conjunto de datos *Iris*, un estándar en problemas de clasificación.

2. Desarrollo

La práctica se dividió en tres etapas: manipulación de arreglos, gestión de DataFrames y generación de gráficos estadísticos.

2.1. Cálculo Numérico con NumPy

Se exploró el objeto `ndarray`, el cual permite almacenar datos homogéneos de forma contigua en memoria, optimizando el rendimiento frente a las listas estándar de Python.

- **Creación de arreglos:** Se utilizaron funciones como `np.array()`, `np.zeros()` y `np.arange()` para generar vectores y matrices.
- **Propiedades:** Se inspeccionaron atributos como `.shape` (dimensiones) y `.dtype` (tipo de dato).

2.2. Análisis de Datos con Pandas

Se cargó el *Iris Dataset* desde un repositorio remoto utilizando `pd.read_csv`. Las operaciones principales incluyeron:

- **Exploración inicial:** Uso de `.head()` para visualizar las primeras filas y `.info()` para verificar tipos de datos y valores nulos.
- **Estadística descriptiva:** El método `.describe()` permitió obtener rápidamente la media, desviación estándar y cuartiles de las características (largo y ancho de sépalos/pétalos).

```python
import pandas as pd
url = "https://raw.githubusercontent.com/uiuc-cse/data-fa14/gh-pages/data/iris.csv"
df_iris = pd.read_csv(url)
print(df_iris.describe())
```

Listing 1: Carga y exploración del dataset Iris

2.3. Visualización de Datos

Para comprender la distribución y relación entre las variables, se generaron las siguientes gráficas:

1. **Histogramas:** Para observar la distribución de frecuencias del ancho del sépalo.

2. **Diagrama de Dispersión (Scatter Plot):** Se comparó la longitud del sépalo vs. la longitud del pétalo, coloreando por especie.

3. **Mapa de Calor (Heatmap):** Se visualizó la matriz de correlación para identificar variables dependientes.

3. Análisis de Resultados y Reflexión

A partir de las gráficas y tablas generadas, se responden las siguientes preguntas de reflexión sobre el comportamiento de los datos:

1. ¿Qué ventajas ofrece un arreglo de NumPy frente a una lista de Python?

Los arreglos de NumPy (`ndarray`) son significativamente más eficientes en términos de memoria y velocidad de ejecución. Al almacenar datos de un solo tipo en bloques contiguos de memoria, permiten realizar operaciones vectorizadas (aplicar una operación a todo el arreglo simultáneamente) sin necesidad de bucles `for` explícitos, lo cual es esencial en el entrenamiento de modelos de IA.

2. ¿Qué patrones se observan en el diagrama de dispersión de las especies?

Al graficar la longitud del pétalo contra el ancho del pétalo, se observa que la especie *Iris Setosa* forma un clúster linealmente separable de las otras dos especies (*Versicolor* y *Virginica*). Esto sugiere que las dimensiones del pétalo son características discriminantes muy fuertes para clasificar esta especie.

3. ¿Qué nos indica el mapa de calor sobre las variables?

El mapa de calor de correlación mostró valores cercanos a 1 (correlación positiva fuerte) entre la longitud del pétalo y el ancho del pétalo. Esto indica redundancia de información: si conocemos el largo del pétalo, podemos predecir con alta precisión su ancho. En modelos de Machine Learning, identificar estas correlaciones ayuda a reducir la dimensionalidad o seleccionar mejores características.

4. Conclusión

El Laboratorio 2.4 permitió evidenciar el poder de Python para el análisis de datos. La combinación de Pandas para la estructuración y Seaborn para la visualización facilita la identificación rápida de patrones, como la separabilidad de la clase *Setosa* en el dataset Iris. Estas herramientas constituyen la base técnica necesaria para las etapas de preprocesamiento en cualquier proyecto de Aprendizaje Automático.

5. Bibliografía

- McKinney, W. (2017). *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*. O'Reilly Media.
- Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, 9(3), 90-95.
- Waskom, M. L. (2021). Seaborn: statistical data visualization. *Journal of Open Source Software*, 6(60), 3021.